TP Hadoop: Introduction au Map Reduce

Mastère Big Data 2019/2020

Benjamin Thery - benjamin.thery@grenoble-inp.org

1. Prise en main

1.1 Execution locale

Question 1. Que signifie Map input records? Et Map output records?

Map input record : nombre de lignes du fichier d'entrée en entrée du Mapper. **Map output record** : nombre d'enregistrements produits en sortie du Mapper.

Question 2. Quel est le lien entre Map output records et Reduce input records?

Leur valeur est la même.

Les Map output records sont les enregistrements qui vont servir d'entrée aux Reducers.

Question 3. Que signifie Reduce input groups?

C'est le nombre de clés uniques (mots uniques) passées en entrée des Reducers.

1.2 Premier contact avec HDFS

Connection au serveur Hadoop: ssh theryb@152.77.81.30

Commandes HDFS:

```
$ hdfs dfs
```

```
$ hdfs dfs -ls /user
...
drwxr-xr-x - theryb theryb 0 2019-10-21 14:57 /user/theryb
...
```

\$ hdfs dfs -ls /user/theryb

Question 1. Quel est le chemin, dans HDFS, vers votre répertoire personnel ?

Le chemin d'accès vers le répertoire personnel est /user/theryb

1.3 Exécution sur le cluster

Compter le nombre d'occurrences de chaque mot dans les 5 tomes des Misérables de Victor Hugo.

Question 1. A quel compteur le nombre de splits correspond-il?

Le nombre de splits correspond au compteur *Launched map tasks* quand aucune tache n'a échoué,

ou à *Launched map tasks - Failed map tasks* quand certaine taches ont échoué et ont du être relancées.

1.4 Combiner

Ajouter un combiner :

```
job.setCombinerClass(WordCountReducer.class);
```

Dans le programme proposé, on ne peut réutiliser directement la classe WordCountReducer telle quelle car ces types d'entrée ne correspondent pas aux types de sortie (int vs long). Une nouvelle classe **WordCountCombiner** similaire WordCountReducer a été ajoutée mais avec une signature différente :

```
public static class WordCountCombiner extends Reducer<Text, IntWritable, Text, IntWritable> { \dots }
```

Fichier source: WordCount/WordCountWithCombiner.java

Question 1. Quels compteurs permettent de vérifier que le combiner a fonctionné?

Les compteurs *Combine input records* et *Combine output records* permettent de vérifier que le combiner à fonctionné. Leur valeur est non nulle lors de l'exécution avec le combiner.

Question 2. Quels compteurs permettent d'estimer le gain effectivement apporté par le combiner ? Comparez aux valeurs obtenues sans combiner pour justifier votre réponse.

Diff des compteurs de sortie entre l'exécution sans le combiner (-) et avec le combiner (+) :

- Combine input records=0
- Combine output records=0
- + Combine input records=401392
- + Combine output records=55487
 - Reduce input groups=29373
- Reduce shuffle bytes=4677667
- Reduce input records=401392
- + Reduce shuffle bytes=800835
- + Reduce input records=55487

Les compteurs *Reduce input records* et *Reduce shuffle bytes* permettent d'estimer le gain apporté par le combiner.

Reduce input records est beaucoup plus petit dans le cas où un combiner a été utilisé : ~55'000 < ~400'000. Beaucoup moins d'enregistrements ont été poussés en entrée du reducer (seulement 14%).

Question 3. Quel est le mot le plus utilisé dans Les Misérables ?

Le mot le plus utilisé dans les Misérables est **de** avec 16955 occurrences.

```
$ sort -r -n -k 2 part-r-00000 | head -10
de
     16955
la
     12253
et
     10979
le
     9810
il
     7660
les
     6059
     5112
un
     4430
que
dans 4235
qui
     4225
```

1.5 Nombres de reducers

Utiliser 3 reducers:

```
job.setNumReduceTasks(3)
```

Source file: WordCount/WordCountWithCombiner.java

Question 1. Quelle est la différence entre le répertoire de résultats obtenu ici, et celui de la partie 1.3 ? Pourquoi ?

Le répertoire de résultats contient maintenant 3 fichiers de sortie, un par reducer. Chaque reducer a généré ses résultats sur le sous ensemble de clés qui lui a été assigné.

```
$ ls
part-r-00000 part-r-00001 part-r-00002 _SUCCESS
```

Le résultat global peut-être retrouvé en concaténant les fichiers résultat de tous les reducers :

```
$ cat part-r-00000 part-r-00001 part-r-00002 | sort -r -n -k 2 | head -5
de    16955
la    12253
et    10979
le    9810
il    7660
```

1.6 In-Mapper Combiner

Ajout d'un in-mapper combiner à l'aide d'une table de hashage.

Fichier source: WordCount/WordCountWithInMapperCombiner.java

1.7 Compteur

Ajout d'un compteur pour enregistrer le nombre de lignes vides dans les données.

Fichier source: WordCount/WordCountWithInMapperCombinerWithCounter.java

```
INFO LocalJobRunner - reduce > reduce
INFO Task - Task 'attempt_local1212808654_0001_r_000000_0' done.
```

2. Top-tags Flickr par pays, avec tri en mémoire

2.1 Map et Reduce

Fichier source: MostUsedTags/MostUsedTagsPerCountry.java

Résultats pour les 5 tags les plus utilisés par pays du fichier flickrSample.txt:

Sortie avec tags aggrégés par pays par le reducer:

```
$ cat out/part-r-00000

AG (3) الطوارق, algeria(3), amazigh culture(3), (3) تمنراست, hoggar(3)

BN ghana(7), lab(5), africa(2), idds(2), single mothers(1)

ML mali(15), niger(11), islam(10), rio niger(10), desierto(10)

UV africa(10), burkina-faso(9), afrique(9), burkina faso(9), ghana(8)

Unknown rojer(6), orangevale(6), rojer wisner(6), rww(6), roger beach(6)
```

Sortie brute:

```
$ cat out/part-r-00000
AG
      الطوارق
ΑG
      algeria
ΑG
      amazigh culture
ΑG
      تمنراست
      الهقار
AG
BN
      ghana
BN
      lab
BN
      africa
BN
      idds
BN
      single mothers
ML
      mali
ML
      niger
ML
      islam
ML
      viajes
ML
      rio niger
UV
      africa
UV
      burkina-faso
UV
      afrique
      burkina faso
UV
UV
      ghana
Unknown
            rojer
Unknown
            orangevale
Unknown
            rojer wisner
Unknown
            rww
Unknown
            roger beach
```

Notes:

- Dans le jeu de données, certaines entrées n'ont pas de tags, elles sont exclues par le mapper. J'ai ajouté un compteur Hadoop pour les compter.
- La classe Country ne trouve pas de pays pour certaines coordonnées présentent dans le fichier flickrSample.txt (par exemple (-1.0,-1.0)). Je les ai regroupées dans un pays « Unknown ». Il y aussi un compteur Hadoop pour les compter.
- Dans la sortie avec tags aggrégés, les chaines contenant des tags en langue arabe sont écrits en RTL par Java (right-to-left), le nombre d'occurrences du tag se retrouve à gauche.

2.2 Combiner

Fichier source: MostUsedTags/MostUsedTagsPerCountryWithCombiner.java

Question 1: Pour pouvoir utiliser un combiner, quel devrait être le type des données intermédiaires ? Donnez le type sémantique (que représentent ces clés-valeurs ?) et le type Java.

Pour pouvoir utiliser un combiner le type de données intermédiaires devrait être de type:

- Clé : **Text** (code pays)
- Valeur : **(Text, Int)** (tag, nombre d'occurrence du tag)
 - Cela permet de commencer à compter le nombre d'occurrence de chaque tag d'un pays dans le combiner et de passer cette première agrégation au reducer.
 - En Java, on peut réutiliser la classe *StringAndInt* pour représenter le tuple (Text, Int) qui représente un tag et son nombre d'occurrences.

Mapper:

- Input: (Long, Text)
- Ouput: (Text, (Text, Int))
- Signature Java :

```
public static class MostUsedTagsMapper
   extends Mapper<LongWritable, Text, Text, StringAndIntWritable> {}
```

Combiner:

- Input : (Text, (Text, Int))
- Ouput : (Text, (Text, Int))
- Signature Java:

```
public static class MostUsedTagsCombiner
   extends Reducer<Text, StringAndIntWritable, Text, StringAndIntWritable> {}
```

Reducer:

- Input : (Text, (Text, Int))
- Ouput : (Text, Text)
- Signature Java:

```
public static class MostUsedTagsReducer
    extends Reducer<Text, StringAndIntWritable, Text, Text> {}
```

Question 2 : Quels sont les tags les plus utilisés en France ?

Les 5 tags les plus utilisés pour la France :

FR

Les tags 'barcelona' et 'spain' apparaissent probablement car l'algorithme de la classe Country doit considèrer que les coordonnées de Barcelone sont plus proches du centre de la France que de celui de l'Espagne.

Note: Sur le jeu de donnée /data/flickr.txt, contenant 20 millions d'enregistrements, mon programme en a trouvé 8'033'752 sans tags et 9'866'381 sans coordonnées (ou pour lesquelles la classe Country ne retourne pas de pays).

Question 3 : Dans le reducer, nous avons une structure en mémoire dont la taille dépend du nombre de tags distincts : on ne le connaît pas a priori, et il y en a potentiellement beaucoup. Est-ce un problème ?

Oui, c'est un problème. Dans un cas extrême avec un très grand nombre de tags, la hashmap utilisée pour compter les occurrences de chaque tags associés à un pays pourrait ne pas tenir dans la mémoire allouée au reducer. La réduction pourrait ne pas être exécutée.

3. Top-tags Flickr par pays, avec mémoire limitée